Projet Data Mining – Analyse de données médicales

Livrables :
- Rapport PDF
- Code Python complet et commenté

1. Objectif général

Ce projet vise à analyser un jeu de données médical en appliquant :
- Des règles d'association
- Des techniques de classification supervisée
- Des méthodes de clustering non supervisé

L'objectif est d'évaluer, comparer et visualiser les performances des différentes techniques.

2. Jeu de données (à choisir)

- Heart Disease Dataset (UCI) https://archive.ics.uci.edu/dataset/45/heart+disease
- Diabetes Dataset (Pima Indians) https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database
- Breast Cancer Wisconsin Dataset https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic

Ou tout autre dataset médical structuré (avec attributs + classe cible).

3. Étapes du projet

3.1 Prétraitement des données

- Nettoyage des données manquantes et doublons
- Encodage des variables catégorielles
- Normalisation/standardisation
- Analyse exploratoire avec graphiques

3.2 Règles d'association

- Application d'Apriori - Extraction de règles (ex : antécédents médicaux → diagnostic)

Métriques :

Support : Support(A → B) = (Transactions contenant A ∪ B) / (Nombre total de transactions)
Confiance : Confiance(A → B) = Support(A ∪ B) / Support(A)
Lift : Lift(A → B) = Confiance(A → B) / Support(B)

3.3 Classification supervisée

Algorithmes à tester :
- Decision Tree

- Random Forest
- K-Nearest Neighbors
- AdaBoost

Métriques à utiliser :

Accuracy = (TP + TN) / (TP + TN + FP + FN)
Precision = TP / (TP + FP)
Recall = TP / (TP + FN)
F1-score = 2 * (Precision * Recall) / (Precision + Recall)
Visualisation des résultats par bar plots.

3.4 Clustering non supervisé

Méthodes à comparer :
- KMeans
- Clustering hiérarchique (agglomératif)

Visualisation des clusters en 2D et dendrogramme

Métriques d'évaluation :

Courbe du coude (Elbow Method)
Courble de silhouette

4. Livrables attendus

- Rapport PDF incluant :
  - Méthodologie, prétraitement, choix des modèles
  - Résultats chiffrés avec graphiques
  - Interprétations des règles, classification et clustering
  - Comparaison entre les approches
- Code Python complet (Notebook ou .py)